

인공지능 학습용 데이터 구축·활용 가이드라인

< 뉴스 대본 및 앵커 음성 데이터 >

인공지능 학습용 데이터 구축·활용 가이드라인	사업 총괄	타임소프트
	데이터 설계	타임소프트
	데이터 획득(수집)	대본 : 케이엘큐브 음성 : 타임소프트
	데이터 정제	타임소프트
	데이터 가공	코난테크놀로지
	데이터 검사	에이스솔루션
	클라우드 소싱	타임소프트, 케이엘큐브, 코난테크놀로지, 에이스솔루션
	저작도구 개발	음성분할(타임소프트)
	AI모델 개발	타임소프트
	데이터 활용	없음
데이터 구축·활용 가이드라인 작성	타임소프트	이성춘
	케이엘큐브	장철성
	코난테크놀로지	김원준
	에이스솔루션	박봉현
데이터 구축·활용 가이드라인 버전	ver 1.0 (‘23. 01. 31)	

제.개정 이력

[illegible]

목 차

제1장 데이터 명세	1
1. 데이터 정보 요약	1
2. 데이터 포맷	2
3. 어노테이션 포맷	4
4. 데이터 구성	5
5. 데이터 통계	6
6. 원시데이터 특성	8
7. 기타 정보	8
제2장 데이터 구축	9
1. 데이터 구축 개요	9
2. 임무 정의	9
3. 획득(수집)	10
4. 정제	16
5. 가공(라벨링)	21
6. 검사	26
7. 학습 모델	33
제3장 데이터 활용	35
1. 데이터 활용	35
2. 기술 지원	36

제1장 데이터 명세 정보

1. 데이터 정보 요약

데이터 명	뉴스 대본 및 앵커 음성 데이터	
활용 분야	주어진 뉴스 대본 텍스트의 단락 및 테이블 대상 기계 독해 기술 연구, 비정형 데이터 질의-응답, 대화형 시스템 등의 연구에 활용	
데이터 요약	아나운서 교육 이수, 경력이 있는 다수의 발화자들이 뉴스 대본을 이용하여 음성을 녹음한 데이터	
데이터 출처	대본 출처 : 한국언론진흥재단 음성 원시데이터 출처 : 발화자가 직접 녹음	
데이터 통계	데이터 구축 규모	음성 1,000시간, 대본 4400건
	데이터 분포 (충분성, 균등성, 편향성 여부 확인)	다양성(요건) : 학습요건을 충족 정치(15%), 경제(20%), 사회(10%), 문화(10%), 국제(10%), 지역(15%), 스포츠(10%), IT과학(10%)
데이터 이력	배포 버전	1.0
	개정 이력	신규
	작성자/배포자	이성춘

2. 데이터 포맷

구분	No	속성명	속성 및 내용
필수	1	script	대본정보
필수	2	id	대본고유ID
선택	3	url	기사URL주소
필수	4	title	기사제목
필수	5	press	언론사
필수	6	press_field	보도분야
필수	7	press_date	보도일자
필수	8	index	발화순번
필수	9	text	발화텍스트
필수	10	sentence_type	문장분류
필수	11	keyword	키워드
필수	12	speaker	발화자정보
필수	13	id	고유발화자ID
필수	14	age	연령
필수	15	sex	성별
필수	16	job	직업
필수	17	file_information	파일정보
필수	18	audio_format	음성포맷
필수	19	utterance_start	발화시작시간
필수	20	utterance_end	발화종료시간
필수	21	audio_duration	음원길이(초)

분류	내용
음성/텍스트	 ! 박근혜 전 대통령이 국정원 특수활동비를 수수한 혐의로 추가 기소되면서 재판·병합을 비롯한 향후 공청회·형량에 관심이 쏠리고 있습니다.
라벨	<pre> { "script": { "id": "YTN00000001001", "url": "http://www.ytn.co.kr/_ln/0102_201803090031524138", "title": "성동조선 법정관리...STX는 자력생존 확정", "press": "YTN", "press_field": "경제", "press_date": "20220221", "index": 1, "text": "수조 원의 공적자금이 들어간 증권 조선사인 성동조선헤양이 결국 법정관리에 들어갔습니다.", "sentence_type": "작문형[요약형]완전직접인용형" }, "speaker": { "id": "SPK001", "age": "20대", "sex": "남성", "job": "현직아나운서" }, "file_information": { "audio_format": "44000Hz 32bit PCM", "utterance_start": "0.428", "utterance_end": "8.192", "audio_duration": "8.597" } } </pre> < JSON 파일 예시 >

구분	획득(수집) 단계	정제 단계	가공(라벨링) 단계
데이터 구분	원시데이터	원천데이터	최종데이터
데이터 형태	대본 -> 음성 (아날로그 → 디지털 파일)	음성 → 음성 (원시 음원 → 문장단위 음원)	디지털 파일 형태로 산출
데이터 포맷	* 데이터포맷 : WAV 파일 44,100Hz / Mono / 16bit	* 데이터포맷 : WAV 파일 44,100Hz / Mono / 16bit	* 데이터포맷 : WAV 파일 44,100Hz / Mono / 16bit * 가공데이터: JSON 파일

3. 어노테이션 포맷

뉴스 대본 및 앵커 음성 데이터 학습 데이터를 위한 어노테이션 포맷은 아래와 같습니다.


구분	속성명	타입	필수	속성설명
1	script	object	Y	대본정보
	1.1	id	Y	대본고유ID
	1.2	url	N	기사URL주소
	1.3	title	Y	기사제목
	1.4	press	Y	언론사
	1.5	press_field	Y	보도분야
	1.6	press_date	Y	보도일자
	1.7	index	Y	발화순번
	1.8	text	Y	발화텍스트
	1.9	sentence_type	Y	문장분류
	1.10	keyword	Y	키워드
2	speaker	object	Y	발화자정보
	2.1	id	Y	고유발화자ID
	2.2	age	Y	연령
	2.3	sex	Y	성별
	2.4	job	Y	직업
3	file_information	object	Y	파일정보
	3.1	audio_format	Y	음성포맷
	3.2	utterance_start	Y	발화시작시간
	3.3	utterance_end	Y	발화종료시간
	3.4	audio_duration	Y	음원길이(초)

4. 데이터 구성

뉴스 대본 및 앵커 음성 데이터 학습데이터는 아래와 같이 구성됩니다.

No.	Field Name	Length	Meaning
1	press	1	KBS(K), SBS(S), MBC(M), YTN(Y), OBS(O)
2	press_field	2	정치(PO), 경제(EC), 사회(SC), 문화(CU), 국제(IN), 지역(LO), 스포츠(SP), IT과학(IT)
3	sentence_type	1	작문형(C), 요약형(S), 완전직접인용형(Q)
4	age	1	20대(2), 30대(3), 40대(4), 50대(5), 60대(6)
5	sex	1	남성(M), 여성(F)
6	job	1	아나운서준비생(F), 현직아나운서(P), 전직아나운서(B)

라벨링 데이터가 저장되는 폴더는 아래와 같이 구성됩니다.



5. 데이터 통계

5.1 데이터 통계


5.1.1 데이터 구축 규모


원시데이터 현황	
대상 인원	음원 개수
86	47,330

원천데이터 현황			
대상 인원	음원 개수	라벨링 개수	데이터 형식
86	381,456	381,456	- 음원: WAV - 라벨링: JSON

학습데이터 현황				
	Training	Validation	Testing	Total
할당비율(%)	80%	10%	10%	100%
음원 개수	306,728	35,875	38,853	381,456
텍스트 개수	306,728	35,875	38,853	381,456

5.1.2 데이터 분포





6. 원시데이터 특성

6.1.1 대상분류

- 실제 (방송사에서 보도된 뉴스를 스크립트로 사용)

6.1.2 제약조건

- 제약있음
데이터 수집 조건 : 한국언론진흥재단에서 보유한 방송사(KBS, MBC, OBS, SBS, YTN) 뉴스
1)기간 : 2022년 6월 기준 최근 6년동안의 뉴스 중 선정
2)조건 : 3문단 이상 200글자 이상 뉴스대본 중 인터뷰 내용 제외한 스크립트

6.1.3 속성

- 발화 시간

7. 기타 정보

7.1.1 포괄성

- 한국언론진흥재단에서 보유한 방송사(KBS, MBC, OBS, SBS, YTN) 뉴스 중 대분류로 정의된 분야(정치, 경제, 사회, 문화, 국제, 지역, 스포츠, IT과학)를 대상으로 함

7.1.2 독립성

- 뉴스대본은 한국언론진흥재단에서 보유한 뉴스대본을 원시데이터로 하고 있으나 별도의 발화규칙 적용 및 인터뷰 내용 제외로 별도의 정제과정을 거치고 있음
- 스크립트(대본)에 개인정보 비식별화, 민감정보를 포함하고 있지 않음

7.1.3 유의사항

- 파급효과
수요기관인 스포티비 아카데미와 봄온아카데미에서 교육용 자료로 활용할 계획
AI-HUB에 50명의 가상 목소리 모델을 개방하여 누구나 쉽게 음성합성을 활용할수 있음
- 유의사항


유의사항	설명
도메인	데이터에 포함되어 있지 않은 도메인의 경우 AI활용에 다소 어려움이 있음
뉴스대본 스크립트 활용	도메인 범위의 악성민원, 욕설, 민감정보 등 비정상적인 상담내용은 포함하고 있지 않음
발화자 구분 정의	원천데이터의 발화자는 아나운서의 주 연령대(30~60대)로 구성하여, 미성년자와 고령자(70대이상)에 대한 데이터는 포함하고 있지 않음

7.1.4 관련 연구

- 관련 연구 없음

제2장 데이터 구축

1. 데이터 구축 개요



2. 임무 정의

2.1 임무 정의

■ 추진배경

• TTS, 우리말로로는 '음성합성 시스템'이라 부른다. 보통 TTS라고 하면 이것을 의미한다. 컴퓨터의 프로그램을 통해 사람의 목소리를 구현해내는 것으로, 성우 없이도 거의 모든 단어와 문장의 음성을 쉽게 구할 수 있다. 하지만 사전녹음된 목소리 자료를 기반으로 쓰는 만큼 역량이 자연스럽지 못하다는 단점이 있다. 국내 언론 및 방송국이 진행자의 음성합성 기술을 통해 최근 인공지능 앵커를 도입하는 것뿐만 아니라 다양한 서비스로 발전하기 위한 시도를 하고 있다. 이와 같은 기술은 특이사항 발생 시 속보 형태로 정보를 전달하는 데에 이점이 있는 반면에 특정단어 즉 주제어를 조회하여 기사를 전달하는 데에 어려움을 겪고 있다.

■ 추진 목적

- 언론 및 라디오 분야에서 인공지능이 활용되는 비중이 커지고 있으며, 정보를 전달하는 매체인 만큼 보다 더 정확한 정보를 전달하여 편의성 제공을 목적으로 한다.
- 인공지능의 기계독해 기술의 향상을 위해 뉴스 앵커들을 대상으로 한 음성이기 때문에 발음의 정확성 또한 높일 수 있기에 범용성 높은 오픈소스 음성데이터를 제공한다.
- 아나운서 교육생, 현직 아나운서, 전직 아나운서 같은 전문적인 발화 가능자를 활용함으로 발음의 정확성 확보 및 클라우드 위커를 활용을 한다.

2.2 데이터 구축 유의사항

• 개인 정보 보호 문제

본 과제는 대본 수집 시 개인정보나 민감정보를 비식별 처리한 결과를 바탕으로 수집 되었기 때문에 위 개인정보나 민감정보와 관련하여 문제가 될 소지는 없으나 추후 위 데이터를 바탕으로 활용할 시 개인정보 보호와 관련된 문제 발생 시 아래와 같은 대처 방안을 따른다.

• 대처 방안


개인정보보호 관련하여 위 수탁 업무를 단계별로 아래와 같이 관리 한다.

- 1) 개인 정보 처리 위 수탁 전
 - 개인 정보 처리 위탁 업무
 - 개인 정보 위 수탁 문서 작성
- 2) 개인 정보 처리 위 수탁 업무 수행 중
 - 수탁자의 개인정보 처리
- 3) 개인정보처리 위 수탁 업무 종료 후
 - 수탁자의 개인정보의 파기 및 반환
 - 위탁자의 파기 및 보고

3. 획득(수집)

3.1 원시데이터 선정

- 원시데이터 4,000건 이상의 뉴스대본 스크립트
- 한국언론진흥재단에서 보유한 방송사(KBS, MBC, OBS, SBS, YTN) 뉴스를 구매하여 원시데이터 확보
- 한국언론진흥재단과 뉴스대본 제공협약을 통한 저작권 획득



- 원시데이터 구조/형태

원시 데이터 포맷	스크립트 : xml
<pre> <?xml version="1.0" encoding="UTF-8"?> <NewsML> <Catalog Href="http://newsml.or.kr/topicset/MasterCatalog.xml" /> <NewsEnvelope> <DateAndTime>20180309T004402+0900</DateAndTime> </NewsEnvelope> <NewsItem> <Identification> 종락 금지</CopyrightLine> <CopyrightLine>[저작권자(c) YTN & YTN PLUS 무단전재 및 재배포 <RightsLine></RightsLine> <SeriesLine></SeriesLine> <SlugLine></SlugLine> <KeywordLine></KeywordLine> </NewsLines> <AdministrativeMetadata> <FileName>08100401.20180309004402001.xml</FileName> <Provider> <Comment xml:lang="ko">YTN</Comment> </pre>	


<Party FormalName="08100401" />	
</Provider>	
.....중략	
<DataContent><![CDATA[[앵커]	
수조 원의 공적자금이 들어간 중견 조선사인 성동조선해양이 결국 법정관리에 들어갔습니다.	
또 다른 부실 조선사인 STX 조선은 고강도 자구 노력을 조건으로 일단 자력 생존이 결정됐습니다.	
보도에 김세호 기자입니다	
[기자]	
성동조선해양이 채무를 일단 동결하고 법원에 회생 여부를 맡기는 법정관리 절차에 돌입하게 됐습니다.	
성동조선은 2조5천억 원 이상 빚에 한 해에 갚아야 할 이자만 5백억 원에 이릅니다.	
주력 선종인 중대형 탱커의 수주 부진 등으로 이익을 내기 어렵고,	
수리 조선소나 블록공장 등의 대안도 장기간 순손실이 불가피한 것으로 파악됐습니다.	
[김동연 / 부총리 겸 기획재정부 장관 : 업황 전망, 경쟁력, 추가 구조조정 방안 등을 종합적으로 감안하여	
성동조선은 법원에 의한 회생정착, 법정관리가 불가피하고..]	
특히 성동조선은 유동성 부족으로 당장 2분기에 부도가 불가피할 정도로 심한 자금난을 겪고 있습니다.	
이미 법정관리를 통해 회생했지만 생존 여부가 여전히 불투명한 STX 조선은 자력 생존으로 운명이 결정됐	
습니다.	
산업은행의 관리하에 고정비 감축과 자산 매각 등 고강도 자구계획이 마련되며, 액화천연가스, 액화석유가	
스선 등 고부가가치 가스 선주로 사업재편이 추진됩니다.	
산업은행은 성동조선에 이어 STX 조선까지 일시 정리할 경우 조선 산업 전반의 생태계가 무너질 수 있어	
자력 생존에 맡기기로 했습니다.	
다만 다음 달 9일까지 고강도 구조조정과 40% 이상 인력감축 등 노사합의를 내지 않으면 원칙대로 다시	
법정관리에 넣을 방침입니다.	
YTN 김세호입니다.]]></DataContent>	
.....중략	

- 데이터 규모 및 분포

데이터 통계	데이터 구축규모	대본 4,000건	
	데이터 분포	분야	규모(%)
		정치	15%
		경제	20%
		사회	10%
		문화	10%
		국제	10%
		지역	15%
		스포츠	10%
		IT과학	10%

3.2 획득(수집) 절차

- 뉴스대본 스크립트 수집 방법



- 뉴스대본 스크립트 절차

가. XML → XLS 변환(부적합 및 중복 파일 제거)

구분, 뉴스원본 XML 데이터, 뉴스주제, 언론사, 뉴스제목, 보도일자, 대본

200문자 이하 자동 변환 불가

변환 작업은 중복 데이터 확인 가능

나. 스크립트 작업 (ETRI 전사규칙에 의거된 발화작업 및 중복파일 추가 제거)

스크립트 작업 전

- 작업전 발화시 문제 되는 인덱스 등 점검
- 주제/제목과 내용 일치 여부 확인
- 기본 작업과 중복 내용 점검

스크립트 작업 후

- 전사규칙에 의거 한 이름전사 진행
- 발화 작업에 불필요한 단어/문구 삭제
- Metadata 정보 확인 (ID, 보도주제 등)
- 발화순번 확인 및 EOF(종료) 표기
- 내용 중복 사항 점검

다. 수집 파일 저장

- * 작성한 파일들은 타임소프트에서 구매한 데이터 저장용 서버에 일자별로 업로드를 진행
- * 작업자들의 작업효율을 높이기 위하여 서버구성(SFTP) 후 RaiDrive를 활용하여 업/다운로드를 손쉽게 처리



< RaiDrive >

3.3 획득(수집) 기준

- 데이터 선별 기준

- 가. 원시데이터의 뉴스대본은 한국언론진흥재단에서 보유한 2022년 6월 기준 최근 6년 동안의 방송사(KBS, MBC, OBS, SBS, YTN) 뉴스를 대상으로 수집.
- 나. 원시데이터 수집 규모는 원천데이터(4,000건)에 추가 10%하여 4,400건을 수집하며, 뉴스 분야는 한국언론진흥재단의 뉴스분야 기준으로 정치, 경제, 사회, 문화, 국제, 지역, 스포츠, IT과학 8개 분야로 구분.
- 다. 분야별 수집된 뉴스는 사실관계 전달여부와 기자의 보도내용인지 확인하고, 3문단 이상과 최소 200자 이상인지 확인하여 선정



- 스크립트 작성 기준

- 가. 스크립트 작성 전 유형별 주제 분류 확인
- 나. 뉴스대본의 개인정보(성명, 주민번호, 전화번호 등) 비식별화
- 다. 특정인물 비하, 욕설 등 민감이슈 표기 수정
- 라. 특수문자, 숫자, 알파벳 등은 한글로 이중전사 표기(통상적 발음)
- 마. 국립국어원 한글 맞춤법 및 표준어 준수

- 스크립트 작성 규칙

- 가. 외국어/외래어/약자
 - * 외국어 문자가 있을 경우, 통상의 발음대로 읽은 경우는 통상의 한글표기를 따른다
 - * 알파벳, 약자 등은 한글로 표기하며, 애매한 경우도 한글로 표기한다
 - 예시) KBS → 케이 비 에스 YTN → 와이 티 엔 S&P →에스 앤 피
- 나. 숫자/도량형/기타 단위 표현
 - * 기본적으로 숫자는 모두 한글로 표현한다

- * 숫자는 발음한 형태를 반영하여 한글로 표현하며, 십진 단위로 띄어 쓴다
예시) 22 →이십 이
- * 숫자를 하나씩 발음한 경우에도 띄어 쓴다
예시) 코로나19 → 코로나 일 구
- * 날짜를 나타내는 ‘년’, ‘월’, ‘일’, ‘시’, ‘분’ 등은 숫자와 띄어 쓰며 특정 의미의 날짜는 통상 사용하는 단어로 표기한다
예시) 5시45분 → 다섯 시 사십 오 분
8.15 광복절 → 팔 일 오 광복절
- * 도량형 및 온도 등의 기타 단위는 한글문자로 표현한다
- 다. 특수기호, 기타부호 표기
 - * 특수기호 및 기타부호의 사용 시에는 통상의 한글표기로 표현한다
예시) 3 ~ 4 → 삼 에서 사
 - * 대본 내에 인정되는 부호는 . , ? ‘(어퍼스트로피)’(작은 따옴표: 인용문에 사용)만 인정되며 그 외의 아래의 표에 의거하여 이중전사로 표기한다
- 라. 인터뷰 내용 (파일 전체삭제)
 - * 파일화된 대본은 인터뷰가 []나 <인터뷰>로 표기가 되는데 이 파일은 삭제한다
예시) [이재정 경기도교육감: 학교의 유형이 여러 가지로 만들어져야만 한다라고 저는 그렇게 생각합니다.]
- 마. 괄호 내용 (내용 삭제)
 - * 예시) 안 의원(경기 오산) → 안 의원
예외) <한국 정원 기행>이 출간됐습니다 → 한국 정원 기행이 출간됐습니다
- 바. 인사말 및 마무리 멘트 (내용 삭제)
 - * 예시) 클로징멘트로 박대기 기자입니다. 지금까지 날씨였습니다 는 2개의 문장 모두 삭제한다
예시) 앵커가 김대영 기자입니다. 라고 말하는 경우 김대영 기자입니다라는 문장을 삭제한다
- 사. 번호와 기호 삭제
 - * 예시) 1. 요르단입니다 → 요르단입니다
예시) ▲국가과학기술연구회 → 국가과학기술연구회
- 아. #로만 문장 (#####)
 - * 셀을 더블 클릭하여 내용을 보고 여러 문장을 각각 나누어 사용한다.
 - * 단, 맨 하단에 나오는 #####으로만 된 것을 보면 회사이름들(단어들)로만 나열된 경우도 있는데 이 경우는 삭제한다
- 자. 불필요 단어 삭제
 - * 예시)【앵커】,【기자】,【기상캐스터】,【리포터】,【앵커멘트】
<영상취재 : 김OO 영상편집 : 이OO> 이OO(abc1234@obs.co.kr)
- 차. 상당히 유사한 내용의 파일은 삭제한다/ 간혹 보도내용과 다른 내용이 하단에 2셀정도 나오는 경우도 있으나 그냥 그 파일은 사용한다
- 카. 이중 전사한 단어 앞과 뒤는 반드시 띄운다
- 타. 하나의 셀에 ? 와 . 으로 여러 문장이 들어간 경우 삽입기능을 사용하여 각각의 문장으로 표현한다

3.4 획득(수집) 조직

●운영조직도



- XML → 엑셀 변환 작업 진행시 유사도율 확인을 통하여 중복을 제거
유사도율은 오라클 함수 중 편집거리 알고리즘(Levenshtein Distance) 사용하여 유사도율을 판단.

[illegible]

- 스크립트 작성예시

번호	17961365	제목	후쿠시마 수산물 수입 규제, 일련번호 표기 철폐가이드
Metadata		URL	https://www.mhlw.go.jp/stf/stf04_0002020202_20120804/
연호사		YTN	
보도주제		경제	
보도일자		2020526	
보도분류명		0910409_2020526121202081.html	
키워드		한국수출 규제,후쿠시마수산물수입 차단,수출 일본,후쿠시마수산물 수입 규제,CFR99,가공수입 규제,수산물 수입,후쿠시마수산물 수입	
발행처(외국 소식처)		발행처: 연합뉴스	
발행처: 일본		발행처: 로이터	
지언		지언	
발행주제	공정경제	농수지재	
1		일본 정부가 한국에 대해 후쿠시마 수산물 수입 규제를 조기에 철폐해줄 것을 요구했습니다.	
2		일본 정부와 미국, 캐나다, 프랑스, 영국, 독일, 이탈리아, 중국, 미국, 한국, 호주, 뉴질랜드, 인도, 한국에 대해 '09104'라는 한국에 대해 '09104'라는 것을 통해 일본의 수출의 관세율과 과학적 근거를 바탕으로 실효성 평가가 필요합니다.	
3		이러한 일본 수산물 수입 규제를 철폐하는 것은 일본의 최대 과학자와 한국에 대해 조기에 철폐를 강하게 요구할 것이라고 말했습니다.	
4		또한 일본 정부와 미국, 캐나다, 프랑스, 영국, 독일, 이탈리아, 중국, 미국, 한국, 호주, 뉴질랜드, 인도, 한국에 대해 '09104'라는 것을 통해 일본의 수출의 관세율과 과학적 근거를 바탕으로 실효성 평가가 필요합니다.	
5		일본 정부는 'CFR99'의 미국, 한국, 호주, 뉴질랜드, 인도, 한국에 대해 '09104'라는 것을 통해 일본의 수출의 관세율과 과학적 근거를 바탕으로 실효성 평가가 필요합니다.	
6		일본 정부는 'CFR99'의 미국, 한국, 호주, 뉴질랜드, 인도, 한국에 대해 '09104'라는 것을 통해 일본의 수출의 관세율과 과학적 근거를 바탕으로 실효성 평가가 필요합니다.	
7		한국에 대해 'CFR99'의 미국, 한국, 호주, 뉴질랜드, 인도, 한국에 대해 '09104'라는 것을 통해 일본의 수출의 관세율과 과학적 근거를 바탕으로 실효성 평가가 필요합니다.	
EDF			


4. 정제

4.1 원천데이터 규모

원천데이터 종류	수집음원 수	언론사 수
SPK003	2870	5
SPK004	7963	
SPK005	5873	
SPK006	6259	
SPK007	648	
SPK008	6834	
SPK009	6993	
SPK010	5822	
SPK011	3950	
SPK012	6954	
SPK013	7354	
SPK014	6877	
SPK015	7214	
SPK016	7034	
SPK017	47	
SPK019	3959	
SPK020	3076	
SPK021	7063	
SPK022	2981	
SPK023	2042	
SPK024	6754	
SPK025	5683	
SPK026	1822	
SPK027	6081	
SPK028	4568	
SPK029	4164	
SPK030	3131	
SPK031	1950	
SPK032	5122	
SPK033	6622	
SPK034	7289	
SPK035	1000	
SPK036	7326	
SPK037	6943	
SPK038	7718	
SPK039	4999	
SPK040	2358	
SPK041	6192	
SPK042	4229	
SPK043	707	
SPK044	4494	
SPK045	4236	
SPK046	3568	
SPK047	5589	
SPK048	4732	
SPK049	1643	

SPK050	2406	
SPK051	6151	
SPK052	3964	
SPK053	2848	
SPK054	280	
SPK055	6844	
SPK056	2045	
SPK057	6594	
SPK058	4885	
SPK059	474	
SPK060	7209	
SPK061	6795	
SPK062	6083	
SPK063	1231	
SPK064	4377	
SPK065	6232	
SPK066	6871	
SPK067	5944	
SPK068	4256	
SPK069	6644	
SPK070	990	
SPK071	2250	
SPK072	3122	
SPK073	625	
SPK074	5839	
SPK075	6124	
SPK076	3880	
SPK077	2652	
SPK078	2797	
SPK079	4620	
SPK080	6485	
SPK081	5469	
SPK082	652	
SPK083	107	
SPK084	1314	
SPK085	5428	
SPK086	6289	
SPK087	2534	
SPK088	2919	
SPK089	4494	

4.2 정제 절차



4.3 정제 기준

자동분할된 원천데이터를 청취하여 대본과 일치 여부를 확인합니다. 잡음, 클리핑 등이 들어가 있으면 재녹음 처리를 하며 문장 단위로 분할되지 않은 음성은 audacity를 이용하여 분할을 합니다.

검수 방법

음원폴더 음원 6개 / 대본 발화문장 6문장 이 일치하는지 확인


‘음원 6개 재생 및 대본파일을 열어 대본과 음원이 일치하게 녹음되었는지 검수’

행	뉴스기사
1	지휘자 정명훈이 [실] [말] 세에서 [이실] [말] 세 연주자 [실] [말] 행으로 구성된 팀 코리아 유스 오케스트라를 창단했습니다.
2	팀 코리아 유스 오케스트라는 뛰어난 기량과 리더십을 갖춘 오케스트라 전문 연주자를 양성하기 위한 목적으로 국내에서는 처음 기획했으며 롯데문화재단이 후원합니다.
3	오디션은 작년 [말] 월 말부터 [구] 월 초 사이 진행됐으며 선발된 단원들은 정명훈 음악감독을 비롯해 해외 유명 오케스트라 연주자들로부터 집중 지도를 받고 연습해 왔습니다.
4	정명훈 씨는 언젠가 북한 연주자와 함께 연주하는 게 최종 목표이며 특히 북한의 어린이들과 어려운 사람들을 위해 음악으로 도움될 일이 있으면 무엇이든 해야 한다는 생각이라고 밝혔습니다.
5	팀 코리아 유스 오케스트라의 창단 공연은 [실] [말] 일 오후 [여말] 시 롯데콘서트홀에서 열립니다.
6	이예 말서 [말] 일 오후 [다섯] 시에는 교수진으로 참여하는 세계적인 오케스트라 연주자들의 실내악 공연이 열립니다.

음원편집 프로그램(audacity)으로 음원 편집


묵음 구간 만들기

- 묵음을 만들 특정 부분을 선택 후 묵음처리




2. 해당 부분을 드래그 하여 **Ctrl+I** (해당 부분 묵음처리 됨)


4.4 정제 조직



4.5 정제 도구




Audacity는 대표적인 무료 음성 편집기 중 하나이며 잡음이 들어가거나 음성을 분할을 할 때 사용됩니다.



5. 가공(라벨링)

5.1 가공(라벨링) 절차


라벨링 가공 단계는 크게 태깅 작업과 라벨링 작업 2가지로 구분되며, 각 작업에서는 작업과 검수 단계로 구성됩니다.



5.1.1 작업 폴더 구성 및 작업 방식

케이엘큐브에서 작업한 대본이 저장된 “00.케이엘큐브_대본업로드” 폴더를 기반으로 태깅 및 라벨링 작업을 수행합니다. 먼저 작업할 대본 데이터를 “00.코난_대본문장태깅” 폴더로 복사 후 태깅 작업을 수행합니다. 태깅 작업이 완료된 데이터는 라벨링 작업을 통해 라벨링 데이터를 생성하고, 이를 “04.라벨링데이터” 폴더에 저장하여 최종 데이터를 생성합니다.

“00.코난_대본문장태깅” 폴더는 “00.케이엘큐브_대본업로드”와 동일한 폴더구조로 데이터를 구성하였으며, “04.라벨링데이터” 폴더는 음성데이터와 동일한 구조로 폴더를 구성하였습니다.



5.1.2 태깅 작업

태깅 작업은 대본의 문장을 검토한 후 문장형태 가이드에 맞춰 문장형태를 구분, 정의하는 프로세스입니다. 태깅 작업을 통해 “완전직접인용형”, “요약형”, “작문형”의 문장으로 구분하며, 이는 각 크라우드 작업자, 내부 작업자를 통해 작업을 수행합니다.

A	B	C	D
1	id	KBSP0002	
2	metadata	제목	[KBS 여론조사] 지방선거 때 새 안을 뽑겠다 56.8%...개혁 투표 찬성
3		URL	http://news.kbs.co.kr/news/View.do?ncd=3589481&ref=DA
4		연문사	KBS
5		보도주제	정치
6		보도일자	20180102
7		원본파일명	08100101.20180102100553002.xml
8		키워드	퍼센트,지방선거 투표,지방선거 투표 찬성,조사 응답자,홈페이지,KBS,안철수 후보,성연남,조사 의뢰
9		발화자ID(교유 스피커ID)	
10		발화자 연명	
11		발화자 성별	
12		직업	
13	발화순번	문장형태	뉴스기사
14	1	이어서 오는 (6)/(육) 월에 치러지는 지방선거와 개혁에 대한 민심을 알아봅니다.	
15	2	이번 지방선거에선 지금의 시장이나 도지사보단 새 안을 뽑겠다는 의견이 우세했습니다.	
16	3	또 대다수가 개혁 국민투표를 지방선거와 함께 실시하는 방안에 찬성했는데, 지금의 대통령 중심제	
17	4	헌법 광역단체장이 (6)/(육) 월 지방선거에 다시 출마한다면 어떻게 하겠느냐고 물었습니다.	
18	5	헌법 단체장에게 투표하겠다는 응답은 (29.6)/(이십 구 점 육) 퍼센트에 그쳤고, 다른 후보를 뽑겠다	
19	6	지방선거에서 어느 정당 후보에게 투표하겠다는 물음엔 더불어민주당 후보가 (48)/(사십 팔) 퍼센	
20	7	단순히 지지 정당을 뽑은 결과도 지방선거 투표 의향과 큰 차이가 없었습니다.	
21	8	다만, 지난 대선 당시 안철수 후보에게 투표했던 응답자의 (27.5)/(이십 칠 점 오) 퍼센트, 유승민 후보	
22	9	(6)/(육) 월 지방선거의 싹에 대해선 문재인 정부 중간 평가란 의견이 (56.5)/(오십 육 점 오) 퍼센	
23	10	지방선거와 함께 개혁 국민투표를 시행하는 것에 대해서 찬성한다가 (82.5)/(팔십 이 점 오) 퍼센트	
24	11	헌법에 명시할 권력 구조로는 대통령 권한을 중립 공화라는 분권형 대통령제를 선호한다는 응답	
25	12	야당 지지자들은 분권형 대통령제 선호가 뚜렷한 반면, 여당 지지자들은 의견이 갈렸습니다.	
26	13	이번 조사 응답자 가운데 지난 대선에서 문재인 후보를 뽑은 사람의 비율은 (53.8)/(오십 삼 점 팔	
27	14	(KBS)/(케이비에스) 가 한국리서치에 의뢰해 시행한 이번 조사는 지난달 (27)/(이십 칠) 일과 (28)/(	
28	EOF		

발화순번	문장형태	
1	작문형	이어서 오는 (6)/(육) 월에
2	작문형	이번 지방선거에선 지금의
3	작문형	또 대다수가 개혁 국민투표
4	완전직접인용형	헌법 광역단체장이 (6)/(육)
5	요약형	헌법 단체장에게 투표하겠
6	작문형	지방선거에서 어느 정당 후
7	완전직접인용형	단순히 지지 정당을 뽑은
8	완전직접인용형	다만, 지난 대선 당시 안철
9	요약형	(6)/(육) 월 지방선거의 성
10	작문형	지방선거와 함께 개혁 국민
11	작문형	헌법에 명시할 권력 구조로
12	작문형	야당 지지자들은 분권형
13	요약형	이번 조사 응답자 가운데
14	요약형	(KBS)/(케이비에스) 가 한


5.1.3 태깅 검수

태깅이 완료된 대본에 대해서는 검수자를 통해 검수 작업을 수행합니다. 잘못된 태깅 정보를 발견할 시에는 수정 후 저장해서 최종 수정이 완료된 대본을 배포하여 라벨링 데이터의 기초 데이터를 사용합니다.



5.1.4 라벨링 작업

라벨링 작업은 문장 태깅이 완료된 대본 데이터와 녹음된 데이터를 기반으로 생성하며, 최종 생성된 파일은 JSON 형태로 제공됩니다. “03.원천데이터” 폴더 내에 녹음이 완료된 WAV 파일과 “00.코난_대본문장태깅” 폴더의 파일을 기반으로 라벨링 데이터를 생성하고, 생성된 라벨링 데이터는 “04. 라벨링 데이터” 폴더에 “03.원천데이터” 폴더와 동일한 폴더구조로 생성하게 됩니다.



5.1.5 라벨링 검수

생성된 라벨링 데이터(JSON)는 구문 정확성과 의미 정확성을 검토합니다. 또한, 중복 라벨링에 대한 데이터를 확인 후 제거하는 방법을 사용합니다.

```
{
  "script": {
    "id": "YTNCU668",
    "url": "https://www.ytn.co.kr/_ln/0101_202204141004417158",
    "title": "정부, 오늘부터 '특별여행주의보' 해제",
    "press": "YTN",
    "press_field": "문화",
    "press_date": "20220414",
    "index": 1,
    "text": "정부가 전 국가, 지역에 대한 특별여행주의보를 코로나 (19)/(일 구) 확산 이후 (2)/(여) 년여 만에 해제했습니다.",
    "sentence_type": "완전직접인용형",
    "keyword": "여행경보 발령, 발령 국가, 외교부, 국가별 여행경보, 여행경보 발령 해제, 코로, 특별여행주의보, 주의보, 국가별, 외교부 해외안전여행"
  },
  "speaker": {
    "id": "SPK003",
    "age": "40대",
    "sex": "여성",
    "job": "전직야나운서"
  },
  "file_information": {
    "audio_format": "44100 Hz 16bit PCM",
    "utterance_start": "0.467",
    "utterance_end": "7.760",
    "audio_duration": "8.235"
  }
}
```

5.2 가공(태깅) 기준

가공 업무 시 문장에 대한 태깅 기준은 아래와 같습니다.

문장분류	구분방법	예시
완전직접인용형	- 문장 내에 ‘(어퍼스트로피)’로 묶여 있는 문장이 있으면서, ‘를’ 말한 주체가 ‘ ’ 밖에 존재하는 경우 - 문장이 “~은(는) ~했습니다. 라고 말했습니다.” 또는 “~은(는) ~입니다. 라고 밝혔습니다.”, “~하라.”와 같이 인용형문장을사용하면서 인용한 문장이 맺음말로 끝나는 형태 - 문장에 ‘(어퍼스트로피)’로 묶여있지는 않지만, 문맥상 인용형의문장을 가지고 있으며, 문장맺음말이 “~은(는) ~했습니다. 라고 말했습니다.” 또는 “~은(는) ~입니다. 라고 밝혔습니다.”, “~하라.”와 같이 끝맺음 하는 경우 - 선행 문장에 주체가 있고“완전직접인용형” 문장으로 판단한 후 다음 문장이 같은 인용한 내용이라고 판단한 경우, 다음 문장에 주체가 없더라도 동일하게 “완전직접인용형”으로 표기	* 불턴전 대사는 선제 군사력이 가장 매력적 대안으로 제시되지 않는 미국 내 대화를 김정은이 본 것이 분명하다고 분석했습니다. * 국민의당은 일단 환영하면서도 근거없는낙관보다는 한미동맹을 바탕으로 한 정교한 외교 전략을 구사하라고 당부했습니다. * 오늘 첫 통화에서 북한은 먼저 전화를 걸어왔지만 아직 회담 관련 언급은 없었다고 통일부가 밝혔습니다. * (CNN)/(씨엔엔)은 평창 대표단 파견 언급과 관련해, ‘김정은이 남한에 화해의 손길을 내밀었다’고 평가했고, 블룸버그통신은 이 제안이 한미 동맹의 견고함을 시험하는 계기가 될 수도 있다고 분석했습니다.
요약형	- 문장이 함축적인 내용을 담고 있는 문장 - 인용한 문장이 맺음말이 아닌 “~것”, “~임” 등으로 문장 맺음이 끝나는 형태 - 문장 내에 ‘(아포스트로피)’로 묶여 있는 문장이 있으면서, 말한 주체가 ‘(아포스트로피)’ 안에 존재하는 경우 - 선행 문장에 주체가 있고“요약형” 문장으로 판단한 후 다음 문장이 이어서 요약된 문장으로 판단한 경우, 다음 문장에 주체가 없더라도 동일하게 “요약형”으로 표기선행 문장에 주체가 있고 “요약형” 문장으로 판단한 후 다음 문장이 이어서 요약된 문장으로 판단한 경우, 다음 문장에 주체가 없더라도 동일하게 “요약형”으로 표기	* 장 씨는 지난해 (11)/(십 일) 월부터 한 달 동안 서울과 경기 일대의 휴대전화 매장 (10)/(열) 곳을 돌면서 노루발못뽑이, 일명 빠루를이용해 문을 부수고 범행을 벌인 것으로 조사됐습니다. * 하지만, 이 시점에 발표한 것을 놓고, 미국 재무부가 북중간유류 밀교역의심 사진을 공개하는 등 중국을 압박하자, 중국이 안보리 결의의 철저한 이행을 과시하려는 것으로도 해석된다고 외교소식통은 전했습니다. * 최문순 강원도지사는 북한 대표단이 가능하면 국제유람선을 이용해 속초항으로 올 것을 희망했습니다.
작문형	완전직접인용형, 요약형 문장이 아닌 경우 작문형으로 작성	

5.4 가공(라벨링) 도구

가공 단계에서 라벨링 데이터를 생성하는 도구는 아래와 같습니다.

가공 단계는 총 2 단계를 거쳐 수행합니다.



1. 데이터 수집 단계 : 가공을 위해 음원 정보와 대본 정보를 DB에 저장하는 작업을 수행합니다.
 - DB에 저장하는 과정 중 키워드, 수치 값 등에 대해서는 1차 검증을 수행하여, 오류 정보가 존재하는지 확인합니다.

```
1 package com.korae.exceltodbbatch;
2
3 import org.springframework.boot.SpringApplication;
4
5 @SpringBootApplication
6 public class ExcelToDbBatchApplication {
7
8     public static void main(String[] args) {
9         SpringApplication.run(ExcelToDbBatchApplication.class, args);
10    }
11 }
12
13
14
```

2. 라벨링 생성 단계 : DB에 저장된 데이터를 Json 형태의 파일로 구성하는 작업을 수행합니다.


```
1 package com.korae.dbtojsonbatch;
2
3 import org.springframework.boot.SpringApplication;
4
5 @SpringBootApplication
6 public class DbToJsonBatchApplication {
7
8     public static void main(String[] args) {
9         SpringApplication.run(DbToJsonBatchApplication.class, args);
10    }
11 }
12
13
14
```

Console Output:

```
2023-05-03 09:36:38.952 INFO 32192 --- [main] c.k.d.DbToJsonBatchApplication : Starting DbToJsonBatchApplication using Java 17.0.1 on DESKTOP-8034586 with PID 32192 (C:\Users\cdm1\Documents\프로젝트\22년 인공지능 학습용 데이터 구축·활용 가이드라인(뉴스 대본 및 앵커 음성 데이터)\src\main\java\com\korae\dbtojsonbatch\
2023-05-03 09:36:38.955 INFO 32192 --- [main] c.k.d.DbToJsonBatchApplication : No active profile set, falling back to 1 default profile: "default"
2023-05-03 09:36:40.145 INFO 32192 --- [main] com.zaxxer.hikari.HikariDataSource : HikariPool-1 - Starting...
2023-05-03 09:36:40.274 INFO 32192 --- [main] com.zaxxer.hikari.HikariDataSource : HikariPool-1 - Start completed.
2023-05-03 09:36:40.476 INFO 32192 --- [main] o.s.b.c.r.s.support.SpringBootBanner : No database type set, using meta data indicating: MySQL
2023-05-03 09:36:40.690 INFO 32192 --- [main] o.s.b.c.l.support.SpringBootBanner : No TaskExecutor has been set, defaulting to synchronous executor.
2023-05-03 09:36:40.785 INFO 32192 --- [main] c.k.d.DbToJsonBatchApplication : Started DbToJsonBatchApplication in 2.136 seconds (JVM running for 3.04)
2023-05-03 09:36:40.787 INFO 32192 --- [main] o.s.b.a.b.hikaricp.HikariConfig : Running default command line with: []
2023-05-03 09:36:41.885 INFO 32192 --- [main] o.s.b.c.l.support.SpringBootBanner : 3du [!Launch] (name=jsonBatchJob) launched with the following parameters: {[run.id=0]}
2023-05-03 09:36:41.876 INFO 32192 --- [main] o.s.batch.core.job.support.JobDefinition : Executing step: [jsonBatchStep]
```

6. 검사

6.1 검사 절차



단계	세부단계명	요구사항
1차 검사 (대본제작)	중복/부적합 제거	● 각 언론사별 유사도가 높은 대본은 제외 여부 ● 한 언론사에서 오전, 정오, 오후 뉴스에서 같은 내용을 동일하게 보도하였을 경우 동일 대본이므로 제외 여부 ● 보도내용이 3문단 이하 200자 미만(공백 및 특수문자 제외) 대본 제외 여부 ● 앵커, 기자의 발화 이외의 인터뷰 내용 제거 여부
	메타데이터 속성	● 언론사, 제목, 보도일자, 보도분야, 키워드, URL 추출
	스크립트 검수	● ETRI 전사규칙의 이중전사 규칙에 준용 여부 ● 국립국어원 한글 맞춤법 및 표준어 준수
2차 검사 (음성수집)	대본, 원시데이터 일치 검사	● 원시데이터 파일명 규칙 확인(SPEAKER_ID + SCRIPT_ID)
3차 검사 (음성정제)	대본문장 개수 일치검사	● 대본의 한문장 단위로 음성이 있는지 여부
	전수청취 검사 STT 일치율	● 깨끗한 음성확인을 위하여 헤드셋, 이어폰으로 음성을 확인 ● STT 결과 대본과 일치율 95% 이상
4차 검사 (라벨링)	문장 태깅	● 완전직접인용형, 요약형, 작문형 등 문장분류 기준에 따라 문장에 대한 태깅 정보가 올바르게 적용되었는지 검사
	라벨링	● 구문 정확성 검토를 위해 JSON 문법 위반 사항이 있는지 체크 ● 의미 정확성 검토를 위해 script, file information 등의 세부 데이터에 대한 검토 규정을 생성하고, 이를 통해 정형화된 정보, 범위 내에 데이터가 구성되어 있는지 검토
5차 검사 (전수 교차검사)	스크립트 전사규칙 검사	● 대본제작 과정에서 발생 된 전사규칙, 이중전사, 중복 등이 올바르게 작성되었는지 검사
	음성일치도 검사	● 음성 수집한 파일과 대본이 일치 여부 검사
	문장 유형 분류 검사	● 완전직접인용형, 요약형, 작문형 등 문장분류 기준에 따라 문장에 대한 태깅 정보가 올바르게 적용되었는지 검사
	모델링 음성 품질검사	● 모델링 된 음성 파일에 대한 품질이 양호한지 체크

6.2 검사 기준


구분		기준 (조건)	주요 확인내용 (관리자)
대본 검사	중복/부적합 제거	대본 내용의 중복여부	메타데이터의 보도제목, 키워드 검토를 통한 중복확인
	메타데이터 속성	각 속성값(언론사, 제목, 보도일자, 보도분야, 키워드, URL)	메타데이터가 올바르게 생성되어 있는지 확인
	스크립트 검수	- ETRI 전사규칙의 이중전사 규칙에 준용 여부 - 한글 맞춤법 / 오타	- 이중전사 대상 및 적용 확인 - 맞춤법 / 오타 확인
원시음성 검사	대본, 원시데이터 일치 검사	발화자에게 배포된 대본이 맞는지 파일명을 검사	프로그램으로 일치여부를 확인하고 불일치항목에 대하여 관리자가 청취하여 확인
원천음성 검사	대본문장 개수 일치검사	대본의 문자 개수와 자동분할된 음성파일의 개수 확인	프로그램으로 개수를 비교하여 틀린 원천데이터 리스트를 관리자가 청취하여 확인
	전수청취 검사	대본 문장과 음성의 일치여부 확인	클라우드워커가 작업한 결과를 확인
	STT 일치율	원천데이터를 STT 처리하여 나온 텍스트와 대본 텍스트 일치 확인	관리자가 확인한 결과를 2차로 STT처리하여 일치율이 95%이하인 대상에 대하여 재확인
라벨링 검사	문장 태깅	- 완전직접인용형, 요약형, 작문형 문장에 대한 기준 조건 만족 - 기준 정보는 5.2 가공(태깅)기준 참조	문장형태를 읽어보고 기준에 맞게 작성되었는지 확인
	라벨링	- JSON 문법에 문제가 없는지 검토 - 입력된 데이터 값이 정해진 범위에 해당하는지 검토	라벨링 데이터가 올바르게 생성되어서 정보가 표현되었는지 확인

※ 품질 지표 및 목표

품질특성	항목명	측정 지표	정량 목표	지표 및 목표 설정 근거
다양성 (통계)	음성 파일 길이	시간	통계 확인	-
	보도 일자 분포	구성비	분포 확인	-
	언론사 분포	구성비	분포 확인	-
	문장형태 분포	구성비	분포 확인	-
	화자 연령대 분포	구성비	분포 확인	-
	화자 직업 분포	구성비	분포 확인	-

다양성 (요건)	주제 분포	최소 시간	목표 구축 시간		사업 공고문 참조 (사회, 정치, 경제, 스포츠, IT 등 최소 4개 이상 주제, 주제별 40% 이하)
			정치	150시간	
			경제	200시간	
			사회	100시간	
			문화	100시간	
			국제	100시간	
			지역	150시간	
			스포츠	100시간	
	IT과학	100시간			
		최소값	주제 수 4개 이상		
화자 성별 분포	최소 시간	남성, 여성 각 500시간 이상		구축계획서 P.16	
	최솟값	남성, 여성 각 25명 이상			
	뉴스 대본당 발화 인원수	최솟값	뉴스 1건당 5명 이상		사업 공고문 참조
	뉴스 대본 길이	최소 음절 수	뉴스 1건당 200자 이상 (공백 및 특수문자 제외)		사업 공고문 참조
구문적 정확성	구조 정확성	정확도	100%		TTA 안내
	형식 정확성	정확도	100%		
의미적 정확성	대본 발화 정확도	정확도	99% 이상		대본 형식 및 대본-음성 일치 중요성 고려
	문장형태 분류 정확도	정확도	90% 이상		TTA 권고
유효성	음성합성 품질 수치	MOS	3.4점 이상		선행연구 논문 기준 MOS 4.43(±0.06)이며, 제안 4.0이나 과제조정위원회 결정사항으로 하향조정 논문: Conditional Variational Autoencoder with Adversarial Learning for End-to-End Text-to-Speech

6.3 검사 조직




조직 구분	역할과 책임
품질관리 총괄책임자	- 인공지능 학습용 데이터의 품질관리 총괄 - 원시 데이터 수집부터 학습용 데이터 구축 결과에 대한 구축/검사 작업 및 품질관리 활동을 상호 연계하여 조정, 통제
품질관리 실무책임자	- 인공지능 학습용 데이터의 품질관리 실무 총괄 - 품질관리계획 수립과 품질 검사 결과에 따른 시정조치 개선 대책 타당성을 검토
품질관리 실무협의회	- 인공지능 학습용 데이터의 품질관리 주요 계획, 품질 현안 등의 협의 - 개인정보, 지적재산권 등 관련 법률전문가 자문
프로세스 품질관리 담당	- 구축 프로세스의 준비성, 완전성, 유용성에 대한 품질관리 담당 - 품질 이슈 발생 시 이를 기록하고 개선하는 활동을 수행
데이터 품질관리 담당	- 인공지능 학습용 데이터 적합성 및 정확성에 대한 품질관리 담당 - 품질 이슈 발생 시 이를 기록하고 개선하는 활동을 수행
학습모델 품질관리 담당	- 인공지능 학습용 데이터를 활용한 학습모델에 대한 품질관리 담당 - 품질 이슈 발생 시 이를 기록하고 개선하는 활동을 수행

6.4 검사 도구

품질검사 영역	대본제작 정확성 검사	정체음성 정확성 검사	라벨링 정확성 검사	학습모델 유효성 검사
도구명	육안검수	음성 플레이어 (직접청취)	자체 스크립트	VITS DEMO 서비스
설명	오라클 함수 편집거리 알고리즘 (Levenshtein Distance) 사용하여 유사도를 확인 메타데이터, 문장태깅, 음성 재생을 통한 데이터 검수	클라우드워커가 모든 음성에 대해 직접 청취하여 오자, 탈자, 첨자 등을 확인	JSON 문법 및 Script 값에 대한 정형화된 데이터 또는 범위에 일치하는지 검토하고, 문제 발생 시 log를 통해 문제 도출	뉴스 대본을 입력 후 음성 ID별로 음성을 생성하여 듣고 성능 지표에 따라 MOS 측정 (EXCELLENT 5점, GOOD 4점, FAIR 3점, POOR 2점, BAD 1점)
도구유형	자체개발	윈도우 기본프로그램	자체개발	타임소프트 자체 개발
주요기능	- 스크립트 문장별 오타 및 맞춤법 확인 - 음성, 문장분류, 대본 일치여부 확인	음성재생	- JSON 문법 확인 - 입력 값의 범위 검토	- 음성 생성 - 전체 선택, 전체 선택 해제 - 재생

6.5 기타 품질관리 활동

- 대본의 품질 향상을 하여 데이터수집 단계의 최종 검수는 현직 아나운서 1인의 최종검수 진행



- 뉴스대본 및 앵커음성데이터 유효성 지표(음성인식율) 검증을위한 전문업체 품질검사 진행

‘22년 인공지능 학습용 데이터 구축·활용 가이드라인(뉴스 대본 및 앵커 음성 데이터) v1.0

[illegible]

7. 학습 모델

7.1 학습 모델 후보

데이터 명	뉴스 대본 및 앵커 음성 데이터			
학습 모델 후보	알고리즘	성능지표	선정 여부	선정 사유
VITS	VAE	MOS 4.0 이상	○	1순위
Tacotron2 + WaveGlow	Attention + Flow	MOS 3.86 이상	△	2순위
Tacotron2 + HiFi-GAN	Attention + GAN	MOS 3.77 이상	△	3순위
FastSpeech2 + HiFi-GAN	Transformer + GAN	MOS 3.9 이상	△	4순위

구분	고려 사항	설명
1	적합성	• 뉴스 대본 및 앵커 음성 데이터 학습 데이터셋 구축 목적에 적합한 학습모델인가
2	활용성	인가
3	실현가능성	• 구축된 학습데이터셋을 활용하여 실제 AI 서비스에 적용하고 실현가능성이 높은 모델인가
4	선정 절차	1) 선정기준에 적합한 후보 리스트업 2) 내부 연구원 대상 설문조사를 통해 우선순위 도출 3) 1-cycle 학습모델 개발 4) 성능평가 5) 최종 학습모델 선정

후보 학습모델	적합성	활용성	실현가능성	선정 여부
VITS	상	상	상	O
Tacotron2 + WaveGlow	중	중	하	X
Tacotron2 + HiFi-GAN	중	중	하	X
FastSpeech2 + HiFi-GAN	중	중	하	X

TTS 개발 데모 서비스

VITS DEMO

뉴스 대본 및 앵커 음성 데이터

텍스트 입력

음성 생성

전체 선택

전체 선택해제

☐ Speaker ID: 03 [40대/여성/전직아나운서/08:51:52]

☐ Speaker ID: 04 [20대/여성/아나운서준비생/19:41:32]

☐ Speaker ID: 05 [20대/여성/현직아나운서/17:19:20]

☐ Speaker ID: 06 [20대/여성/아나운서준비생/20:01:03]

☐ Speaker ID: 07 [20대/여성/아나운서준비생/01:53:00]

돌아가기

Speaker ID: 03 [40대/여성/전직아나운서/08:51:52]

숨기기

뉴스 대본 및 앵커 음성데이터 데모페이지입니다

▶ 0:00 / 0:04

🔊 ⋮

Speaker ID: 04 [20대/여성/아나운서준비생/19:41:32]

숨기기

뉴스 대본 및 앵커 음성데이터 데모페이지입니다

▶ 0:00 / 0:03

🔊 ⋮

- 34 -

7.2 학습 모델 개발


① VITS

- (개발 목표) 뉴스 대본과 전문 녹음장비로 수집한 음원 데이터를 활용하여 다양한 목소리 종류의 음성합성
- (개발 내용) 구축되는 학습데이터를 활용하여 발화자의 목소리 구분을 위해 Stochastic Duration Predictor 알고리즘과 음성을 분석하는 Encoder와 음성을 생성하는 Decoder를 이어주는 VAE 알고리즘을 적용하여 End-to-End 음성합성 학습모델인 VITS 기반의 모델을 개발

제3장 데이터 활용

1. 데이터 활용

데이터 명	뉴스 대본 및 앵커 음성데이터
학습 모델	VITS
모델	VITS
성능 지표	MOS 3.4 이상
개발 내용	구축되는 학습데이터를 활용하여 발화자의 목소리 구분을 위해 Stochastic Duration Predictor 알고리즘과 음성을 분석하는 Encoder와 음성을 생성하는 Decoder를 이어주는 VAE 알고리즘을 적용하여 End-to-End 음성합성 학습모델인 VITS 기반의 모델을 개발
응용서비스 (예시 및 유의사항)	동영상 나레이션 음성 생성 및 가상 아나운서, 인공지능 스피커 등 정보를 제공하기 위한 음성생성 분야에 활용 가능  <코난테크놀로지의 코난보이스 서비스>



<네이버의 음성 더빙 서비스 클로바>

2. 기술지원

