

*작성 가이드	• 데이터셋의 국문명, 영문명 모두 필수기재 • 동일 과제에 속한 데이터셋의 소개 내용은 각 데이터셋의 특징을 알 수 있도록 내용을 차별화하여 작성할 것(동일 내용의 반복은 피할 것) • 내용에 삽입된 이미지는 .PNG 포맷(2배 크기)로 저장하여 원본 이미지는 별도 제출할 것 • 내용에 삽입된 표, 그래프 자료는 엑셀 파일에 정리하여 별도 제출 • 내용의 구축기관 정보에 프로젝트 참여 기업 정보는 누락 없이 모두 기재할 것 (주관 수행기관사 책임자 명/전화번호/메일주소 등은 연결 가능한 정보로 기재할 것) • 아래 메타테이블에 데이터 관련 문의처 정보는 데이터 이용자들에게 대한 기술지원이 가능한 기관의 실무 담당자를 지정하여 정보를 기재할 것. 문의시 담당자와 직접 연결이 가능한 정보로 기재 • 아래 메타테이블에 가공기관, 검수기관은 업무 담당 업체명은 누락 없이 모두 기재할 것 • 전화번호의 경우, 개인 휴대폰 전화번호가 아닌 회사유선번호를 기재해야 함(개인정보) • 한글파일(hwp)로 제출 • 카테고리 정의서는 지정엑셀양식에 데이터카테고리 작성하여 제출
-----------------------	---

메타테이블 정보 (다중기입가능)	분야	데이터 유형 ¹⁾	구축 데이터량	원천데이터 형식 ²⁾	라벨링 형식 ³⁾	라벨링 유형 ⁴⁾
	NIA 기입	오디오, 텍스트	1,132시간	wav	json	전사(음성)
	데이터 출처 ⁵⁾	데이터 구축년도	구축기관(총괄)	가공기관	검수기관	
	뉴스보도 기사	2022년	타임소프트	코난테크놀로지	에이스솔루션	
	데이터 문의처	기관명	문의담당자명	전화번호 (유선전화번호기입)	메일주소	
		타임소프트	이성춘	02-2029-5060	choon@timesoft.co.kr	
	데이터 소개	남녀 아나운서의 주제별 뉴스를 보도하는 음성 1,132시간				
	주요키워드	아나운서, 앵커, 뉴스, 음성				
	카테고리 정의서		첨부의 카테고리 정의서 엑셀파일에 데이터카테고리 작성하여 제출(예시참고)			

1) 텍스트, 오디오, 이미지, 비디오,
2) txt, jpg,.....
3) json, csv,.....
4) 내용요약(텍스트), 번역(자연어), 질의응답(자연어), 바운딩박스(이미지/동영상), 키폰트(이미지/동영상), 세그멘테이션(이미지/동영상), 전자(음성)
5) 4대 언론기사, 자체 수집,.....

데이터셋명	국문	뉴스 대본 및 앵커 음성 데이터																																																	
	영문	News Transcript and Anchor Voice Data																																																	
구축목적	다음과 같은 분야에 활용하기 위하여 범용 데이터 구축																																																		
	• 연구 분야 - 주어진 뉴스 대본 텍스트의 단락 및 테이블 대상 기계독해 기술 연구, 비정형 데이터 질의-응답, 대화형 시스템 등의 연구에 활용 • 산업 분야 - 사실 관계 추론 및 웹 기반 질의 응답, 인공지능 스피커 등 - 뉴스 기사를 읽어주는 AI로봇, 비서 서비스 개발 등																																																		
활용서비스	가상 아나운서, AI 비서, AI 스피커 등 안내 또는 정보전달, 나레이션 등의 음성분야에 활용할 수 있음																																																		
소개	방송 언론 뉴스 및 가상의 라디오 및 방송 진행자의 음성합성(TTS) 등을 위한 인공지능 학습용 데이터 구축																																																		
데이터셋 통계 (구축 규모 및 분포)	1. 데이터 구축 규모																																																		
	<table><tr><th>데이터 종류</th><th>규모</th></tr><tr><td>음성 및 라벨링 데이터</td><td>1,132시간</td></tr></table>		데이터 종류	규모	음성 및 라벨링 데이터	1,132시간																																													
	데이터 종류	규모																																																	
	음성 및 라벨링 데이터	1,132시간																																																	
2. 데이터 분포																																																			
<table><tr><th>보도 분야</th><th>남자</th><th>여자</th><th>합계</th><th>비율</th></tr><tr><td>경제</td><td>101:13:35</td><td>101:17:15</td><td>202:30:51</td><td>17.9%</td></tr><tr><td>지역</td><td>91:26:49</td><td>85:14:41</td><td>176:41:30</td><td>15.6%</td></tr><tr><td>정치</td><td>78:01:52</td><td>117:09:19</td><td>195:11:12</td><td>17.2%</td></tr><tr><td>스포츠</td><td>54:26:29</td><td>53:02:44</td><td>107:29:13</td><td>9.5%</td></tr><tr><td>사회</td><td>53:52:33</td><td>78:15:06</td><td>132:07:40</td><td>11.7%</td></tr><tr><td>문화</td><td>53:20:33</td><td>54:06:47</td><td>107:27:21</td><td>9.5%</td></tr><tr><td>국제</td><td>53:15:49</td><td>53:06:12</td><td>106:22:01</td><td>9.4%</td></tr><tr><td>과학IT</td><td>51:50:37</td><td>52:21:06</td><td>104:11:44</td><td>9.2%</td></tr><tr><td>합계</td><td>537:28:17</td><td>594:33:10</td><td>1132:01:32</td><td>100%</td></tr></table>		보도 분야	남자	여자	합계	비율	경제	101:13:35	101:17:15	202:30:51	17.9%	지역	91:26:49	85:14:41	176:41:30	15.6%	정치	78:01:52	117:09:19	195:11:12	17.2%	스포츠	54:26:29	53:02:44	107:29:13	9.5%	사회	53:52:33	78:15:06	132:07:40	11.7%	문화	53:20:33	54:06:47	107:27:21	9.5%	국제	53:15:49	53:06:12	106:22:01	9.4%	과학IT	51:50:37	52:21:06	104:11:44	9.2%	합계	537:28:17	594:33:10	1132:01:32	100%
보도 분야	남자	여자	합계	비율																																															
경제	101:13:35	101:17:15	202:30:51	17.9%																																															
지역	91:26:49	85:14:41	176:41:30	15.6%																																															
정치	78:01:52	117:09:19	195:11:12	17.2%																																															
스포츠	54:26:29	53:02:44	107:29:13	9.5%																																															
사회	53:52:33	78:15:06	132:07:40	11.7%																																															
문화	53:20:33	54:06:47	107:27:21	9.5%																																															
국제	53:15:49	53:06:12	106:22:01	9.4%																																															
과학IT	51:50:37	52:21:06	104:11:44	9.2%																																															
합계	537:28:17	594:33:10	1132:01:32	100%																																															
분포도 <table><tr><th>분야</th><th>남자</th><th>여자</th></tr><tr><td>경제</td><td>101:13:35</td><td>101:17:15</td></tr><tr><td>지역</td><td>91:26:49</td><td>85:14:41</td></tr><tr><td>정치</td><td>78:01:52</td><td>117:09:19</td></tr><tr><td>스포츠</td><td>54:26:29</td><td>53:02:44</td></tr><tr><td>사회</td><td>53:52:33</td><td>78:15:06</td></tr><tr><td>문화</td><td>53:20:33</td><td>54:06:47</td></tr><tr><td>국제</td><td>53:15:49</td><td>53:06:12</td></tr><tr><td>과학IT</td><td>51:50:37</td><td>52:21:06</td></tr></table>		분야	남자	여자	경제	101:13:35	101:17:15	지역	91:26:49	85:14:41	정치	78:01:52	117:09:19	스포츠	54:26:29	53:02:44	사회	53:52:33	78:15:06	문화	53:20:33	54:06:47	국제	53:15:49	53:06:12	과학IT	51:50:37	52:21:06																							
분야	남자	여자																																																	
경제	101:13:35	101:17:15																																																	
지역	91:26:49	85:14:41																																																	
정치	78:01:52	117:09:19																																																	
스포츠	54:26:29	53:02:44																																																	
사회	53:52:33	78:15:06																																																	
문화	53:20:33	54:06:47																																																	
국제	53:15:49	53:06:12																																																	
과학IT	51:50:37	52:21:06																																																	

3. 데이터 시간 측정 방법 및 결과
- 데이터 시간 측정 방법: 파이썬

```
# 음원 파일 개수 및 시간 누적값 초기화
file_count = 0

# 시간 누적값 초기화
acc = 0

# Train Data
train_file_list = sorted(glob.glob('./1.Training/**/**/*wav'))
for i in train_file_list:
    with contextlib.closing(wave.open(i, mode: 'r')) as f:
        frames = f.getnframes()
        rate = f.getframerate()
        duration = frames / float(rate)
        acc += duration
        file_count += 1

# Validation Data
valid_file_list = sorted(glob.glob('./2.Validation/**/**/*wav'))
for i in valid_file_list:
    with contextlib.closing(wave.open(i, mode: 'r')) as f:
        frames = f.getnframes()
        rate = f.getframerate()
        duration = frames / float(rate)
        acc += duration
        file_count += 1

# Test Data
test_file_list = sorted(glob.glob('./3.Test/**/**/*wav'))
for i in test_file_list:
    with contextlib.closing(wave.open(i, mode: 'r')) as f:
        frames = f.getnframes()
        rate = f.getframerate()
        duration = frames / float(rate)
        acc += duration
        file_count += 1

# 초 -> 시:분:초 변환
MinutesGet, SecondsGet = divmod(acc, 60)
HoursGet, MinutesGet = divmod(MinutesGet, 60)

# 음원 파일 개수 출력
print('====음원 파일 개수====')
print('Total File Count:', file_count)

# 데이터 합산 시간 출력
print('====합산 시간====')
print('Total Seconds:', acc)
print("Total Hours: %02d:%02d:%02d" % (int(HoursGet), int(MinutesGet), int(SecondsGet)))
```

- 데이터 시간 측정 결과:

```
=====음 원 파 일 개 수 =====
Total File Count: 381456
=====합 산 시 간 =====
Total Seconds: 4075341.330006779
Total Hours: 1132:02:21
```

- 데이터 파일 개수 및 총 시간

구분	내용
전체 파일 개수	381,456
총 시간	1132:02:21

1. 원천데이터(음성)



2. 라벨링 데이터

구분		속성명	타입	필수	속성설명
1		script	object	Y	대본정보
	1.1	id	string	Y	대본고유ID
	1.2	url	string	N	기사URL주소
	1.3	title	string	Y	기사제목
	1.4	press	string	Y	언론사
	1.5	press_field	string	Y	보도분야
	1.6	press_date	string	Y	보도일자
	1.7	index	int	Y	발화순번
	1.8	text	string	Y	발화텍스트
	1.9	sentence_type	string	Y	문장분류
	1.10	keyword	string	Y	키워드
2		speaker	object	Y	발화자정보
	2.1	id	String	Y	고유발화자ID
	2.2	age	String	Y	연령
	2.3	sex	String	Y	성별
	2.4	job	String	Y	직업
3		file_information	object	Y	파일정보
	3.1	audio_format	String	Y	음성포맷
	3.2	utterance_start	String	Y	발화시작시간
	3.3	utterance_end	String	Y	발화종료시간
	3.4	audio_duration	String	Y	음원길이(초)

< JSON 형식 >

데이터셋 구성

```
{
  "script": {
    "id": "KBSIN031",
    "url": "http://news.kbs.co.kr/news/view.do?ncd=4152872&ref=DA",
    "title": "환경부 '야외 공기청정기 설치,차량 운행제한 확대'",
    "press": "KBS",
    "press_field": "국제",
    "press_date": "20190307",
    "index": 4,
    "text": "높이 (7m)/(질 미터) 로, 대형 출입구를 열어 오염된 공기를 빨아들이는 방식입니다.",
    "sentence_type": "작문형",
    "keyword": "환경부,김소영,환경부 야외,도심 옥상,중국,도심 미세먼지,환경부 야외 공기청정기 설치,폭은,서울,실제 저감"
  },
  "speaker": {
    "id": "SPK008",
    "age": "20대",
    "sex": "남성",
    "job": "아나운서준비생"
  },
  "file_information": {
    "audio_format": "44100 Hz 16bit PCM",
    "utterance_start": "0.491",
    "utterance_end": "5.637",
    "audio_duration": "6.088"
  }
}
```

< JSON 예시 >

데이터셋 구축 수행기관 담당자	주관기관	기관명	책임자명	전화번호 (유선전화번호기입)	메일주소	담당업무
		타임소프트	박유남	02-2029-5060	anmyoo@time soft.co.kr	총괄책임자
	참여기관	기관명	담당업무	기관명	담당업무	
		케이엘큐브	대본제작			

		코난테크놀로지	라벨링			
		에이스솔루션	검수			